# PRI 2021/2022

# IR concepts

- Information retrieval (IR) is finding material (usually documents) of an unstructured nature (usually text) that satisfies an information need from within large collections (usually stored on computers).
- Clustering coming up with a good grouping of the documents based on their contents.
- grepping linear scan through documents.
- index para cada termo (palavra) dizer se existe num documento => binary term-document incidence matrix

### Modules

- Crawling module crawls through a set of objects to gather information;
- Indexing module based on the collection documents will index them;
- Ranking and retrieval module based on IN (expressed as a query), evaluates and ranks the possible results and retrieves them to the user.
- ? Search user interface The interface to interact with the system can be considered a module.

### Binary term-document incidence matrix

• binary term-document *incidence matrix* - linha é termo e coluna é documento. Célula tem 1 se contém.

	Antony and	Julius Caesar	The Tempest	Hamlet	Othello	Macbeth	
	Cleopatra						
Antony	î	1	0	0	0	1	
Brutus	1	1	0	1	0	0	
Caesar	1	1	0	1	1	1	
Calpurnia	0	1	0	0	0	0	
Cleopatra	1	0	0	0	0	0	
mercy	1	0	1	1	1	1	
worser	1	0	1	1	1	0	

Figure 1: Incidence matrix

Dependendo se olhamos para linhas ou colunas temos vetores de 0s e 1s diferentes. Query Brutus AND Caesar AND NOT Calpurnia, usando os vetores de cada term (linha) é 110100 AND 110111 AND 101111 = 100100 => Está no Anthony e na Cleopatra.

- A matriz fica muito esparsa (no exemplo é 99.8% 0s). Uma representação melhor seria listar apenas os 1s (coisas que ocorrem). => Inverted index
- Collection/Corpus é o grupo de documentos em que fazemos pesquisas.
- Documento Unidades em que construimos o IR system sobre.

- AD HOC retrieval o sistema procura devolver documentos, da coleção, relevantes para uma necessidade de informação. Esta necessidade é comunicada ao sistema através de uma one-off query (iniciada pelo utilizador).
- Necessidade de informação é tópico sobre qual o utilizador procura saber mais.
- Query forma como user comunica ao sistema a sua necessidade de informação.
- Relevância um documento é relevante se o utilizador achar que ele contém informação de valor em respeito à sua necessidade de informação.
- Effectiveness Medida com base na Precision e no Recall.

## **Inverted Index**

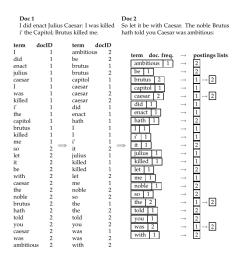


Figure 2: Inverted Index

- Mapeia de termos para documentos.
- Mantemos um dictionary/vocabulary/lexicon.
- Posting list Cada term tem uma lista que guarda os documentos em que o termo aparece (e também a posição).
- **Posting** par (termo, docID).
- Dicionário fica ordenada alfabéticamente e os postings por Document ID.
- Document frequency (df) dictionary também mantém statistics como o número de documentos que contêm cada termo => é a length da posting list.

### Processar boolean query

Q: Brutus AND Calpurnia

- 1. Locate Brutus in the Dictionary;
- 2. Retrieve its postings;
- 3. Locate Calpurnia in the Dictionary;
- 4. Retirve its postings;
- 5. Intersect the two postings lists.
- Merge algorithm interleaved advance dos pointers de cada lista para selecionar o que está em comum (por causa do AND) => faz o intersect.

### Optimization

• Com vários **AND**s, processamos primeiro as que têm uma posting list mais pequenas.

• Com **OR**s, processamos primeiro os lados mais pequenos.

### **Document Unit**

- What we want to index.
- Related to index granularity: precision/recall tradeoff in this decision.
- If the units get too small (sentences), we are likely to miss important passages. If thet are too large (books), we tend to get spurious matches and the relevant information is hard to find.

## **Tokenization**

- Dada uma sequência de characteres e uma definida **document unit**, **tokenization** é a tarefa de a dividir em partes, chamadas **tokens**.
- Token uma instância de uma sequência de chars num document. É agrupado de forma util ao seu processamento semântico.
- Type é a class de todos os tokens que contêm a mesma sequência de chars.

## Stop words

- São de pouco valor para a seleção de documentos no processo de recuperação.
- Collection frequency (cf) olhamos para o numero de vezes que um termo aparece na collection. Útil para determinar quais são stop words.

#### **Token Normalization**

- Canonizar **tokens** para matches ocurrem apesar da existência de diferenças superficiais nas sequência de characteres dos **tokens**.
- Nos acentos, capitalização, stemming, e lemmatization.

- **Stemming** heuristic process that chops off the ends of words in the hope of reducing inflectional forms. Increases **recall** while harming **precision**.
- **Lemmatization** reducing inflectional forms by using vocabularies and the morphological analysis of words to find its **lemma**. É AI para **stemming**.

# Term weighting

### Ranked retrieval

- Large collections need matches to be sorted by rank.
- Scenarios onde recall é deterministico (todos os documentos são analisados), usando Boolean search.

## Parametric and Zone indexes

- Muitos documentos têm estruturas adicionais e meta-data associada.
- Parametric indexes inverted indexes built for specific parameters or fields. Suporta all docs from author Z containing word Y.
- Zones similar concept applied to arbitrary free text (portion of a document).

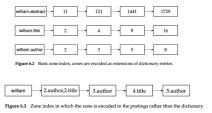


Figure 3: The zones

# Term Frequency (tf)

- Term frequency (tf) Number of mentions of the term in a document.
- Cada documento tem um tf para cada termo la presente.
- Podemos considerar o número de ocorrências de um term dentro de um documento como o seu weight.
- Bag of words quando olhamos para um document como um agregar de terms com os tf. Ordem ignorada e número de ocorrência de cada term é key.

## Inverse Document Frequency (idf)

- Inverse Document Frequency (idf)  $log(\frac{N}{df})$ , where N é o numero de documentos na coleção.
- Incorporated in the weight of a term.
- Quanto mais raro um termo numa coleção, maior o seu idf.

• Documento que aparece em todo o lado => 0.

### tf-idf

- Combinar tf e idf resulta num weighting scheme: tf-idf = tf \* idf
- Para um termo t, num documento d, idf é:
  - highest quando t ocorre muitas vezes num número pequeno de documentos;
  - lower quando o termo ocorre poucas vezes num documento, ou ocorre em muitos documentos;
  - lowest quando o termo está em virtualmente todos os documentos.

# Vector Space Model

- Vector Space Model Representação de um set de documentos como vectors num espaço vetorial comum.
- Each **document** is represented as a vector, with a component vector for each **dictionary term**. **tf-idf** weights are used as components.
- There is one axis for each term for the **document** (vector).

Para cada **term** (por ordem alfabética), pegamos no **td-idf** deles (componentes do vector).

### Cosine similarity

- Similaridade entre documentos é o cosseno do ângulo formado pelas suas representações vetoriais.
- Isto compensa contra o efeito do comprimento do documento.
- $sim(d1, d2) = \frac{V(d1).V(d2)}{|V(d1)|*|V(d2)|}$
- Maior => mais similares.

#### Queries as Vectors

- Queries são vectors num espaço n-dimensional, onde n é o numero de termos na query. Basicamente são vistas como documentos muito curtos.
- Top ranked results são aquelas que têm maior cosine similarity.

## Language Model

### Unigram

### **Bigram**

- Apoia na probabilidade do **term** anterior.
- $P_{bigram}(t1.t2.t3.t4) = P(t1) * P(t2|t1) * P(t3|t2) * P(t4|t3)$

# Example of Retrieval with Language Models

- → D1: Portugal eyes political balance in presidential election
- → D2: After Portuguese elections, Spain braces for elections
- → Q: [portugal election]
- →  $P(q|d_1) = P(portugal|M_{d_1}) \times P(election|M_{d_1}) = 1/7 \times 1/7 = 0.0204$
- →  $P(q|d_2) = P(portugal|M_{d_2}) \times P(election|M_{d_2}) = 1/7 \times 2/7 = 0.0408$

Figure 4: Language model

### Metrics

#### Precision-Recall

- Precision fração dos resultados obtidos que é relevante para a necessidade de informação #(relevant items retrieved)/#(retrieved items) = P(relevant|retrieved).
- Recall fração dos documentos relevantes presentes na collection que foram returnados pelo sistema #(relevant items retrieved)/#(relevant items) = P(retrieved|relevant).

#### Accuracy

- Data is skewed 99.9% dos results são não relevants.
- Maximizar accuracy => dizer que tudo é não relevant.

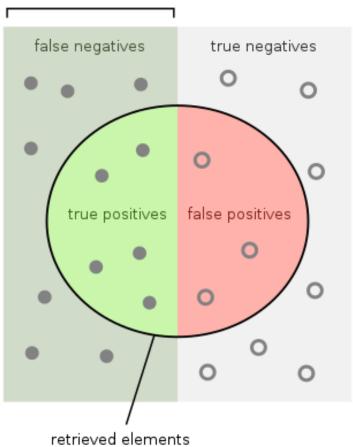
Recall e precision dão tradeoff uma contra a outra:

- Retrieve all documents => 1 recall, but low precision
- Retrieve no documents => 1 precision, but low recall

#### F Measure

- Weighted harmonic mean of recall and precision.
- F1 æ = 1/2; SS = 1 default balanced F measure  $\frac{2*P*R}{P+R}$
- Harmonic mean é usada porque a arithmetic mean dá 50% quando pomos, por exemplo, o recall a 100% (retrieve de tudo).
- Harmonic mean dá um resultado mais próximo do mínimo.

# relevant elements



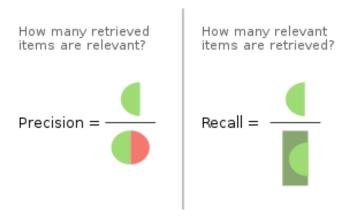


Figure 5: Precision-Recall 7

### PR Curve

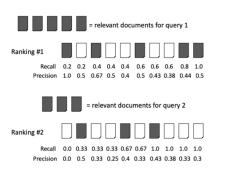


Fig. 8.3. Recall and precision values for rankings from two different queries

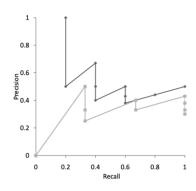


Fig. 8.4. Recall-precision graphs for two queries

Figure 6: PR-curve

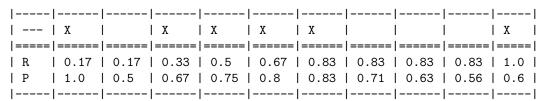
- São jagged porque:
  - quando o documento é não relavante, recall mantém e precision baixa
    - diretamente para baixo;
  - quando o document é relavante precision e recall sobem para cima e direita;
- Interpolated precision precision para cada recall é a maior precision para os recall, r, maiores ou iguais que o atual, r': pinterp(r) = max p(r'), r'>=r.

### 11-point interpolated average precision

- Pegamos na precision interpolada para os recall: 0.0, 0.1, 0.2, 0.3, 0.4, 0.5, 0.6, 0.7, 0.8, 0.9, e 1.0;
- Fazer média aritmética dos valores obtidos para cada ponto nos information needs.

## AvP - Average Precision

 Média aritmetica da precisão para os recall correspondentes a documentos relevantes.



 $AvP = \frac{1+0.67+0.75+0.8+0.83+0.6}{6}$ 

## MAP - Mean Average Precision

• Média das average precisions.

## Precision at k (P@k)

- Majority of users do not require high recall.
- What matters are high quality results on the first page.
- Example: R R N N R N R R R R P@5 = 0.6; P@10 = 0.7
- Problema: Sistema que devolve 10 resultados mas só existe 1 relevante é prefeito mas tem baixa precision.

#### **R-Precision**

- Resolve o Problema de P@K.
- The number of relevant documents, R, is used as a cutoff (varia entre queries).
- Vamos buscar o top R documentos para a query.
- Vemos quantos são relevantes => r.
- R-Precision  $= \frac{r}{R}$
- Intimamente ligada a map.

# Relevance judgement

- Test collection:
  - A document collection;
  - Test suite of information needs (expressible as queries);
  - A set of relevance judgements: usualmente um binary assessment of R or NR for each query-document pair.
- Ground truth/Gold standard judgement of relevance é a decisão se um documento é R ou N para uma information need.
- Relevance é assessed relative to an information need, not a query.

## Web

# Challenges

- Decentralization of content publication no central point that keeps track of what exists/was changed/was deleted.
- What is the size of the web?
- Content is created massively and in diverse forms: diverse languages, formats, quality, and intent.

#### Characteristics

• Modeled as a graph - bowtie model.

- Web pages point tom and pointed by, other pages.
- out-links usually include an anchor text.
- in-degree number of in-links to a page.

### Bowtie model

- SCC (Large) strongly connected core;
- IN Large group of pages that link to the SCC, but aren't linked back from it;
- OUT Large group of pages that is linked by the SCC, but doesn't link back to it;
- Tubes Link from IN to OUT without passing through SCC;
- Tendrils Smaller pages that link to IN or OUT. Tendrils can have Tendrils ad nauseam.

### Spam

- There is commercial value with appearing on the top ranked results for a given search.
- People spam to manipulate search engine result ranking.
- Techniques such as: cloaking (servir um tipo de conteudo a crawlers e outro a user comuns), link farm, link spam, click spam, etc...

## **User Characteristics**

- Users are not trained on how to write queries or the search operators offered by search:
  - -2 or 3 words per search;
  - operators are rarely used
  - precision in the top results is highly valued
  - lightweight result pages prefered
- 3 types of information needs:
  - Information queries seek general info about a topic. Typically there isn't a single source of relevant info (users gather info from multiple web pages).
  - Navigational queries seek the website or home page of a single entity. Users want a to find a specific resource (Can be cached).
  - Transactional queries preludes the user performing a transaction on the web.

### **Signals**

- Used to estimate quality.
- Different dimensions:
  - query-independent (static): titulo, autor, data da ultima modificacao do doc;

- query-dependent (dynamic): hora da query, posição geografica do user, info sobre o user;
- document-based (content or structural), e.g.: HTML;
- Collection-based, e.g.: Links;
- User-based, e.g.: Clicks;

### Web crawling

- Musts: **robust** to problems and traps + **politeness** to web hosts;
- Shoulds: distributed execution + scalable + efficient + bias towards good quality pages + freshness depending on page change rate + extensible

## Near-duplicate detection

- A large percentage of content on the web are near-duplicates (only small differences);
- Standard duplicate detection doesn't work (e.g. fingerprinting);
- Crawlers need to decide if new pages are duplicates of existing content and if page being revisited have changed (estimate change rate);
- Solution: shingles
  - obtain **shingles** of **k** size from web pages;
  - compare shingles
  - the more there are in common, the more similar the pages;
  - Example k=4: "these are red and blue roses" => these are red and + are red and blue + red and blue roses

#### Link-based signals

- Base assumption the number of hyperlinks pointing to a page provides a measure of its popularity and quality.
- Link from A to B represents an endorsement of B by A.

### **PageRank**

- Value between 0 and 1;
- Query-independent value computed offline => only depends on the structure of the web graph;
- Simulate random surfer that begins at a web page and randomly chooses an out-link to move to next. If this goes on forever, some pages are visited more frequently;
- If surfer is stuck (no out-links), teleports to a random page from all pages (equal probability for all, including current position). Surfer also teleports if it is not stuck with probability æ (usually 0.1).

### Example

- 1. Começar numa pagina (primeira) com 100% e o resto tudo a 0, ou, começar na primeira com todas as páginas a igual percentagem.
- 2. Ver as probabilidades de a partir da pagina atual ir para cada uma das
- 3. Ver as pagina que têm prob > 0 agora e onde ligam.
- 4. repetir a partir de 2.

#### HITS

- Query-dependent algorithm;
- Starts with the answer set (pages containing the keywords);
- Computes 2 scores for each page: authrity score and hub score:
  - Pages with many links pointing to them are authorities;
  - Pages with many outgoing links are called **hubs**;

#### Example

- 1. h(v) = a(v) = 1; para todos nodes v;
- 2. a(v) = soma dos h(y) em que y aponta para v;
- 3. h(v) = soma das a(y) em que v aponta para y;
- 4. normalize  $\mathbf{a} \in \mathbf{h}$ :
- $\sum \frac{a(v)}{c}^2 = 1 <=> c = \sqrt{\sum a(v)^2}$ , para todos os  $\mathbf{v} =>$  dividir todos os a(v) por c.
   $\sum \frac{h(v)}{c}^2 = 1 <=> c = \sqrt{\sum h(v)^2}$ , para todos os  $\mathbf{v} =>$  dividir todos os h(v) por c.
- 5. repeat from 2.

## Anchor text as a Signal

- The text in HTML anchors;
- Description about a page from others;
- The collection of all anchor texts can be explored with standard IR techniques and incorporated as an additional feature in an inverted index: important feature for image search.

# Query processing

- **Document-at-a-time** calculates complete scores for documents by processing all term lists, one document at a time. Documents sorted according to their score at the end (otimizar documentos no fim da lista se os docs estiverem ordenados por alguma metrica).
- **Term-at-a-time** accumulates scores for documents by processing term lists one at a time. When all terms are processed, the accumulators contain the final scores of all matching documents (otimizar ignorando stop words).
- Optimization (2 classes):
  - read less data from the index;
  - process fewer documents.

### Conjunctive processing

- Base assumption: so retornar docs que contêm todos os query terms (default em web search e esperado pelos users).
- Funciona melhor quando 1 dos termos é raro (skip de parte da inverted list).
- Short queries beneficio de efficiencia e effectiveness.
- Long queries n são bons candidatos.

#### Relevance Feedback

- Exact matches aren't the only way to obtain relevant results;
- Vocabulary mismatch between the user and the collection, e.g. synonyms exit.
- System side techniques:
  - global methods expand or reformulate the query terms independently of the query or the results: thesaurus + spell correction;
  - local methods adjust a query relative to the documents that initially appear: relevance feedback + pseudo-relevance feedback.

## Query expansion

 Usar synonyms e palavras relacionadas (thesaurus) para generar queries alternativas.

### Relevance feedback (e.g. Rocchio)

- User faz short, simple query.
- User seleciona os relevantes dos resultados inciais dessa query.
- Sistema usa essa info para refinar a query.
- Pode repetir ad nauseam.
- Idea: it is difficult to formulate a good query when you don't know the collection.
- Useful for image search (images can be hard to describe).

- Can improve both recall and precision, but in practice is more useful for increasing recall (users only take the time to refine the query when they want to see an high number of relevant documents).
- Positive feedback is more useful like negative (many systems only allow positive feedback).

### Limitations

- Misspellings + Cross-language retrieval + Vocabulary mismatch;
- Users don't like to provide explicit feedback (they expect single interaction);
- It is often harder to understand why a particular document was retrieved after relevance feedback was applied.

#### Pseudo Relevance feedback

- Automate manual parts of the process;
- Assume top k ranked documents are relevant and apply relevance feedback algorithm under this assumption.

## **Entity Search**

- **Knowledge bases** large scale structured knowledge repositories. Organizam info a volta de objectos chamados **entities**;
- Entities UID, Name(s), Type(s), Attributes, Relationships;
- RDF: Subject (URI) -Predicate (URI de relationship or property)-> Object (URI or literal).

### **Entity-Oriented Search**

- Search paradigm of organizing and accessing information centered around entities (their attributes and relationships);
- From a user prespective, entities are natural units for organizing information. Allowing users to interact with specific entities offers a richer and more effective user experience than document-based search.
- From a machine perspective, entities allow for a better understanding of search queries, document content, and users.

#### Data

- Unstructued data can be found in a vast quatity of forms: web pages, spreadsheets, emails, tweets, etc... All of these can be treated as sequence of words.
- Semi-structured data characterized by the lack of rigid, formal structure. Normalmente tem tags/markup que separa conteudo textual dos elementos semanticos (e.g. HTML data).

• Structured data - adheres to a predefined (fixed) schema and is typically organized in a tabular format (e.g. relation databases). O schema define a organização e impõe contraints para garantir consistencia.

### Tasks Entity-oriented Search

- Entity Retrieval 40% to 70% of web queries target/mention specific entity;
- Entity Linking entities for knowledge representation;
- Entities for an enhanced user experience.

### Ad Hoc Entity Retrieval Task

- Ad Hoc as in the user initiated the search process by formulating and issuing a query.
- Main strategy criar profile document paracada entity com o knowledge sobre ela e fazer pesquisa como se fosse document search.

### Profile document

- Contains all information we have about that entity;
- Serve como representação textual do documento, a entity description;
- Queremos um vector pesado de termos;
- Entity components:
  - Entity length total number of terms in the entity description;
  - Term frequency (TF) normalized term count (by length) in the entity description;
  - Entity frequency (EF) number of entities in which the term occurs:
  - Inverse entity frequency (IEF) log normalized ration between the total number of entities in the catalog, and the entity frequency.

Para dados **semi-estruturados** cada entidade/relação torna-se num field. É importante ter um catch-all field. Não consideramos todas as relações (pk são muitas), juntámos essas relações numa só (**triples**). Algumas relações é dificil extrair texto então vamos buscar a **<foam:name>** ou **<rdfs:label>**.

Ranking é feito como em documentos mas trocando por entity nas equações.

# **Entity Linking**

- Recognizing entity mentions in text and linking them to the corresponding entries in a KB:
  - 1. Mention detection;
  - 2. Candidate selection;
  - 3. Disambiguation;

# Search User Interfaces

- $\bullet\,$  The HCI community has developed the DECIDE process to help on this decision:
  - **D Determine** the goals of the evaluation;
  - **E Explore** the specific questions to be answered;
  - ${\bf C}$   ${\bf Choose}$  an evaluation paradigm;
  - I Identify pratical issues in performing the evaluation;
  - **D Decide** how to deal with any ethical issues;
  - **E Evaluate**, interpret, and present the data.